



T.C.

KONYA TEKNİK ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ

PROJE ADI: KALP SESİ SINIFLANDIRMA

ADI SOYADI: SELBİHAN DEMİR

NUMARASI: 221229046

TARİH: 02.11.2025

1. Giriş

Kalp sesi analizi, kardiyak anormalliklerin erken tespiti için son derece önemli bir biyosinyal işleme problemidir. Bu proje kapsamında, farklı kalp sesi veri setleri birleştirilerek dengeli bir veri kümesi oluşturulmuş, ardından klasik makine öğrenmesi algoritmaları (Random Forest, SVM, KNN) ile derin öğrenme yaklaşımı (1D-CNN) karşılaştırılmıştır. Amaç, hangi modelin bu türden öznitelik temelli verilerde daha etkili sonuç verdiği belirlemektir.

Çalışmanın Amacı

- Kalp sesi sinyallerinden çıkarılan özniteliklerle farklı algoritmaların performansını ölçmek.
- MFCC, Mel, RMS gibi ses temelli özelliklerin sınıflandırma başarısına katkısını analiz etmek.
- Derin öğrenme (1D CNN) mimarisinin klasik yöntemlerle kıyaslandığında avantaj ve dezavantajlarını belirlemek.

Kullanılan Teknolojiler

- **Python 3.13**
- **Kütüphaneler:** numpy, pandas, librosa, scikit-learn, tensorflow, matplotlib
- **Donanım:** CPU tabanlı eğitim (GPU kullanılmadı)
- **Geliştirme Ortamı:** Jupyter Notebook

2. Veri Kümesi ve Hazırlık Süreci

2.1 Veri Seti Kaynakları

Veri, PhysioNet kalp sesi veri setinin alt kümeleri olan **training-a**, **training-b**, **training-c**, **training-d**, **training-e** ve **training-f** dizinlerinden alınmıştır.

Alt Dizin Kayıt Sayısı

training-a 409

training-b 490

training-c 31

training-d 55

training-e 2141

training-f 114

Toplam 3240

2.2 Etiket Dağılımı

- **Normal:** 2575 (%79.5)
- **Anormal:** 665 (%20.5)

Bu dengesiz yapı, modellerin anormal sınıfı tanıtmakta zorlanmasına neden olabileceğinden, örnekleme stratejisi uygulanmıştır.

2.3 Dengeleme (Balancing)

Eğitim sürecinde her iki sınıfın 500'er örnek seçilerek toplam **1000 dosyalık dengeli veri seti** oluşturulmuştur. Bu veri kümesi model eğitimlerinde ortak olarak kullanılmıştır.

3. Özellik Çıkarımı

Kalp sesi dosyaları .wav formatındadır. Her ses dosyası için aşağıdaki öznitelikler çıkarılmıştır.

3.1 Kullanılan Özellikler (38 Adet)

- **Temel İstatistikler:** rms_mean, zcr_mean, signal_mean, signal_std, signal_max, signal_skewness, signal_kurtosis

- **MFCC Özellikleri:** mfcc_0_mean–mfcc_12_std
- **Spektral Özellikler:** spectral_centroid_mean, spectral_rolloff_mean, spectral_bandwidth_mean
- **Mel Özellikleri:** mel_mean, mel_std

Toplamda 38 adet özellik çıkarılmış ve heart_sound_features.csv dosyasına kaydedilmiştir.

3.2 İşlem Süresi ve Kalite

- Toplam dosya sayısı: 1000
- Başarılı çıkarımlar: 1000 / 1000
- Ortalama işlem süresi: 15 saniye (yaklaşık 62 dosya/sn)
- Başarısız dosya: 0

Tüm özellikler daha sonra StandardScaler ile ölçeklendirilmiştir.

4. Makine Öğrenmesi Modelleri

4.1 Veri Bölünmesi

- Eğitim: 800 örnek (%80)
- Test: 200 örnek (%20)

4.2 Kullanılan Modeller

1. **Random Forest Classifier** — 100 ağaç, Gini kriteri, max_depth=None
2. **Support Vector Machine (SVM)** — RBF kernel
3. **K-Nearest Neighbors (KNN)** — k=5, Minkowski metric

4.3 Performans Sonuçları

Model	Accuracy	Precision	Recall	F1-Score
Random Forest	0.895	0.907	0.880	0.893

SVM	0.870	0.885	0.850	0.867
KNN	0.905	0.918	0.890	0.904

Sonuç: KNN modeli en yüksek genel performansı göstermiştir. Özellikle F1 skorunun yüksekliği modelin hem normal hem de anormal sınıfları dengeli biçimde öğrendiğini gösterir.

4.4 Özellik Önemi (Random Forest)

En önemli 10 özellik aşağıda verilmiştir:

1. mfcc_7_mean (0.1173)
2. signal_mean (0.0684)
3. mfcc_0_std (0.0654)
4. mfcc_9_mean (0.0541)
5. mfcc_2_std (0.0459)
6. mfcc_8_mean (0.0394)
7. mfcc_9_std (0.0388)
8. mfcc_5_mean (0.0385)
9. mfcc_6_mean (0.0358)
10. rms_mean (0.0323)

Bu sonuç MFCC özelliklerinin, kalp sesi tanılamasında en bilgilendirici faktörler olduğunu doğrular.

5. Derin Öğrenme (1D-CNN)

5.1 Model Mimarisi

Model, öznitelik vektörlerini (38 özellik) girdi olarak alır. Mimari yapı şöyledir:

Input → Conv1D(64, kernel_size=3) → BatchNorm → MaxPool → Dropout(0.3)

→ Conv1D(128) → BatchNorm → MaxPool → Dropout(0.3)

→ Conv1D(256) → BatchNorm → GlobalAvgPool

→ Dense(128) → BatchNorm → Dropout(0.4)

→ Dense(64) → Dense(2, activation='softmax')

- **Toplam parametre:** 167,106
- **Eğitim optimizasyonu:** Adam optimizer (lr=0.001)
- **Loss:** categorical_crossentropy

5.2 Eğitim Süreci

- Epoch: 100
- EarlyStopping ve ReduceLROnPlateau kullanıldı.
- En iyi epoch: 57
- Öğrenme oranı 3 kez azaltıldı ($0.001 \rightarrow 0.000125$)
- Eğitim süresi: ~6 dakika

5.3 CNN Performans Sonuçları

Metrik Değer

Accuracy 0.86

Precision 0.86

Recall 0.86

F1-Score 0.86

Validation accuracy'nin dalgalı seyretmesi, veri setinin sınırlı olması ve CNN'in özellik uzunluğunun kısa olmasından kaynaklanabilir.

6. Modellerin Karşılaştırması

Model	Accuracy	Precision	Recall	F1-Score
KNN	0.905	0.918	0.890	0.904
Random Forest	0.895	0.907	0.880	0.893
SVM	0.870	0.885	0.850	0.867
CNN (1D)	0.860	0.860	0.860	0.860

Yorum: KNN modeli, bu veri türü için en etkili yöntemdir. Özelliklerin önceden çıkarılıp özetlenmiş olması, klasik modellerin derin ağlardan daha iyi performans vermesini sağlamıştır.

7. Tartışma ve Analiz

7.1 CNN Neden Daha Düşük?

- CNN genellikle ham sinyaller veya uzun sekanslarda daha başarılıdır.
- Burada sadece 38 uzunlukta bir vektörle sınırlıdır — derin konvolüsyonlar fazla bilgi çıkaramaz.
- Öznitelikler zaten özetlendiği için CNN'in otomatik özellik çıkarım avantajı azalmıştır.

7.2 Klasik ML Neden Üstün?

- MFCC gibi tabular veriler için mesafe-tabanlı (KNN) veya ensemble (RF) modelleri uygundur.
 - Az veriyle daha hızlı öğrenir ve genelleme kabiliyeti yüksektir.
-

8. Gelecekteki Geliştirmeler

8.1 Veri Düzeyinde

- Daha fazla anormal örnek toplanmalı.

- **Veri artırma (augmentation)** yapılabilir: gürültü ekleme, zaman kaydırma, ton kaydırma.
- **Gerçek dünya dağılımı** korunarak test seti oluşturulmalı.

8.2 Model Düzeyinde

- **CNN yerine MLP (Dense)** denenebilir, çünkü veri tabuları.
- **2D CNN** ile mel-spectrogram girişleriyle daha iyi performans alınabilir.
- **Transformer tabanlı modeller (wav2vec, AST)** gelecekte değerlendirilebilir.

8.3 Değerlendirme Düzeyinde

- ROC-AUC ve PR-AUC grafiklerini dahil etmek.
 - 5-katlı cross-validation ile sonuçları sağlamlaştırmak.
 - Hiperparametre araması (GridSearch veya Optuna) uygulanmalı.
-

9. Sonuç

Bu çalışmada kalp sesi sinyalleri için klasik ve derin öğrenme modelleri karşılaştırılmıştır. Elde edilen sonuçlar, **KNN modelinin** (Accuracy=0.905, F1=0.9036) en başarılı yöntem olduğunu göstermektedir. Derin öğrenme modeli, mevcut öznitelik setiyle benzer başarıyı yakalayamamıştır, ancak ham sinyal veya spekrogram temelli yaklaşımlarla daha iyi performans beklenmektedir.

10. Ekler

Kaydedilen Dosyalar

- heart_sound_features.csv — çıkarılan öznitelik dosyası
- classical_ml_results.png — klasik modellerin sonuç grafiği
- cnn_complete_results.png — CNN eğitim ve doğrulama grafikleri

Raporu Geliştirme Olanakları

İstenirse:

- Kodlar Jupyter Notebook'a dönüştürülerek eğitim süreci yeniden yürütülebilir.
 - CNN mimarisi 2D spectrogram'a uyarlanabilir.
 - KNN ve RF için hiperparametre optimizasyonu yapılabilir.
-

Genel Sonuç: Tabular veri üzerinde KNN ve Random Forest modelleri klasik yapıda en güçlü performansı göstermiştir. CNN mimarisi ise daha büyük ve zengin özellik temsillerinde tercih edilmelidir.